

Complexidade de Rademacher

No contexto de Teoria do Aprendizado Estatístico, um objetivo central é garantir que um modelo treinado em uma amostra finita apresente um bom desempenho em dados não observados. Seja $\mathcal{F}$ uma classe de funções de hipótese e $\mathbb{P}(f) = \mathbb{E}_{Z \sim \mathbb{P}}[f(Z)]$ o risco esperado (erro real) de uma função $f \in \mathcal{F}$, enquanto $\mathbb{P}_n(f) = \frac{1}{n} \sum_{i=1}^n f(Z_i)$ representa o risco empírico baseado em uma amostra aleatória $Z_1, \dots, Z_n \sim \mathbb{P}$. Estamos interessados em controlar o *gap* de generalização: $\sup_{f \in \mathcal{F}} |\mathbb{P}(f) - \mathbb{P}_n(f)|$.

Teorema 1 (Limite de Generalização via Rademacher). Seja $\mathcal{F}$ uma classe de funções limitadas em $[0, 1]$. Para qualquer $\delta \in (0, 1)$, sobre o sorteio de uma amostra aleatória $Z_1, \dots, Z_n \sim \mathbb{P}$, temos que:

$$\mathbb{P} \left(\forall f \in \mathcal{F} : \mathbb{P}(f) \leq \mathbb{P}_n(f) + 2\mathcal{R}_n(\mathcal{F}) + \sqrt{\frac{\log(1/\delta)}{2n}} \right) \geq 1 - \delta,$$

em que $\mathcal{R}_n(\mathcal{F})$ é a complexidade de Rademacher de $\mathcal{F}$.

Este resultado motiva o estudo de $\mathcal{R}_n(\mathcal{F})$, pois ele controla diretamente o erro de aprendizado. Se a complexidade de Rademacher decresce com n , o aprendizado é garantido.

Definição 1 (Complexidade de Rademacher Empírica). Seja $\mathbf{Z} = (Z_1, \dots, Z_n)$ uma amostra aleatória, então a complexidade de Rademacher empírica de $\mathcal{F}$ é definida como:

$$\widehat{\mathcal{R}}_n(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(Z_i) \right],$$

em que $\sigma_1, \dots, \sigma_n$ são variáveis aleatórias independentes (variáveis de Rademacher) tais que $\mathbb{P}(\sigma_i = 1) = \mathbb{P}(\sigma_i = -1) = 1/2$. A complexidade global é dada por

$$\mathcal{R}_n(\mathcal{F}) = \mathbb{E}_{\mathbf{Z}}[\widehat{\mathcal{R}}_n(\mathcal{F})] = \mathbb{E}_{\mathbf{Z}, \sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(Z_i) \right].$$

Calcular $\mathcal{R}_n(\mathcal{F})$ diretamente pode ser difícil para classes complexas. Para avançar, precisamos entender a "riqueza"/"complexidade" de $\mathcal{F}$ sob uma perspectiva métrica. Para discretizar uma classe de funções contínua, utilizamos o conceito de número de cobertura.

Definição 2 (ε -cobertura). Uma ε -cobertura do conjunto Θ com respeito à métrica d é um conjunto $\mathcal{C} \subseteq \Xi$ tal que $\Theta \subseteq \bigcup_{\theta^* \in \mathcal{C}} B(\theta^*, \varepsilon)$, em que $B(\theta^*, \varepsilon) = \{\xi \in \Xi : d(\theta^*, \xi) \leq \varepsilon\}$.

Definição 3 (Número de ε -cobertura). O número de ε -cobertura do conjunto Θ com respeito à métrica d é dado por

$$\mathcal{N}(\Theta, \varepsilon, d) = \inf\{|\mathcal{C}| : \mathcal{C} \text{ é uma } \varepsilon\text{-cobertura de } \Theta\}.$$

Definição 4. Dizemos que uma variável X ($\mathbb{E}[X] = 0$) é sub-Gaussiana com parâmetro σ^2 se $\mathbb{E}[e^{\lambda X}] \leq \exp(\frac{\sigma^2 \lambda^2}{2})$. Um processo $(X_t)_{t \in T}$ é sub-gaussiano se $X_t - X_s \sim \text{Subg}(d^2(t, s))$.

Para tais processos, o supremo $\mathbb{E}[\sup X_t]$ pode ser limitado pela estrutura métrica de T . O resultado clássico de Dudley utiliza uma técnica chamada encadeamento, em que aproximamos o processo por uma sequência de coberturas cada vez mais finas.

Teorema 2 (Dudley). Seja (T, d) um espaço pseudo-métrico e $\{X_t\}_{t \in T}$ um processo sub-gaussiano com média zero. Então:

$$\mathbb{E} \left[\sup_{t \in T} X_t \right] \leq 12 \int_0^{\text{diam}(T)} \sqrt{\log \mathcal{N}(T, d, \varepsilon)} d\varepsilon.$$

Finalmente, aplicamos o teorema de Dudley à complexidade de Rademacher. Para uma amostra fixada $Z_1, \dots, Z_n$, definimos a métrica $L_2(\mathbb{P}_n)$ entre duas funções $f, g \in \mathcal{F}$ como:

$$d_n(f, g) = \sqrt{\frac{1}{n} \sum_{i=1}^n (f(Z_i) - g(Z_i))^2}.$$

O processo de Rademacher empírico $\hat{X}_f = \frac{1}{n} \sum_{i=1}^n \sigma_i f(Z_i)$ é sub-gaussiano em relação à métrica d_n com parâmetro $1/n$. Ao normalizarmos e aplicarmos o encadeamento, obtemos o limitante superior para a complexidade de Rademacher em termos da integral da entropia métrica.

Teorema 3 (Limitante de Dudley para Rademacher). Seja $\mathcal{F}$ uma classe de funções com valores em $[-M, M]$. A complexidade de Rademacher empírica é limitada superiormente por:

$$\hat{\mathcal{R}}_n(\mathcal{F}) \leq \inf_{\alpha > 0} \left(4\alpha + \frac{12}{\sqrt{n}} \int_{\alpha}^M \sqrt{\log \mathcal{N}(\mathcal{F}, \varepsilon, d_n)} d\varepsilon \right).$$

Em uma versão simplificada, considerando o diâmetro do espaço, temos:

$$\mathcal{R}_n(\mathcal{F}) \leq \frac{C}{\sqrt{n}} \int_0^{\text{diam}(\mathcal{F})} \sqrt{\log \mathcal{N}(\mathcal{F}, \varepsilon, d_n)} d\varepsilon.$$

Este resultado é fundamental para entender a capacidade de generalização de um algoritmo de aprendizado, basta estudar a geometria (número de cobertura) da classe de funções que ele utiliza. Se a "cauda" da integral de Dudley for finita e convergir para zero na taxa adequada, a classe é considerada aprendível.

Sugestões e conclusão

As seguintes referências sobre o assunto são recomendadas:

- *Understanding Machine Learning: From Theory to Algorithms* (Shai Shalev-Shwartz e Shai Ben-David) – Parte 4, Capítulos 26 (*Rademacher Complexities*) e 27 (*Covering Numbers*).
- *Foundations of Machine Learning* (Mehryar Mohri, Afshin Rostamizadeh e Ameet Talwalkar) – Capítulo 3 (*Rademacher complexity and VC-dimension*).
- *A Gentle Introduction to Empirical Process Theory and Applications* (Bodhisattva Sen) – Capítulos 2 (*Size/complexity of a function class*), 3 (*Glivenko-Cantelli (GC) classes of functions*) e 4 (*Chaining and uniform entropy*).

A complexidade de Rademacher e os números de cobertura continuam sendo usados para analisar modelos modernos. Por exemplo, para redes neurais em “*Size-independent sample complexity of neural networks*” (2018), nos mecanismos de autoatenção em “*Inductive biases and variable creation in self-attention mechanisms*” (2022), e no estabelecimento de limites de generalização dos Transformers em “*Sequence length independent norm-based generalization bounds for transformers*” (2024).