

Aprendizado estatístico e concentração

MAC5005 - Fundamentos Matemáticos do Aprendizado Sequencial e Online

Victor S. Portella
IME-USP

2026-02-10 23

Objetivos do curso

Ver **rapidamente** conceitos clássicos de teoria de ML

PAC-Learning, VC-dimension, online learning, boosting, bandits

Escolha de tópicos muito viesada para meus interesses de pesquisa

Objetivos do curso

Ver **rapidamente** conceitos clássicos de teoria de ML

PAC-Learning, VC-dimension, online learning, boosting, bandits

Escolha de tópicos muito viesada para meus interesses de pesquisa

Cobrir **ferramentas úteis** para pesquisa teórica em ML e algoritmos

Concentração, otimização convexa, estimadores não-viesados de gradientes

Objetivos do curso

Ver **rapidamente** conceitos clássicos de teoria de ML

PAC-Learning, VC-dimension, online learning, boosting, bandits

Escolha de tópicos muito viesada para meus interesses de pesquisa

Cobrir **ferramentas úteis** para pesquisa teórica em ML e algoritmos

Concentração, otimização convexa, estimadores não-viesados de gradientes


Achar outras pessoas interessadas nesses assuntos 😊

Questões Logísticas

- **Website do curso** (slides, listas, e leituras recomendadas): ime.usp.br/~victorsp/mac5005
- **Uma lista por semana**
 - Entrega 14h da segunda-feira seguinte
- Tentem usar o Moodle para o perguntas
 - Fiquem a vontade para me mandar e-mails também


Statistical Learning e Online Learning

Aprendendo a Detectar Spam



A partir de exemplos, queremos “aprender” a classificar **e-mails de SPAM**


Aprendendo a Detectar Spam



A partir de exemplos, queremos “aprender” a classificar e-mails de SPAM

Como modelar esse tarefa matematicamente?

Aprendendo a Detectar Spam



A partir de exemplos, queremos “aprender” a classificar **e-mails de SPAM**

Como modelar esse tarefa matematicamente?

- Qual a nossa medida de sucesso?
- Qual a fonte dos dados?
- Quando aprendizado é possível?

Spam via *Statistical Learning*

Aprendizado Estatístico é um dos mais clássicos arcabouços teóricos de ML.

Spam via *Statistical Learning*

Aprendizado Estatístico é um dos mais clássicos arcabouços teóricos de ML.

No Exemplo de Spam:

1 milhão de e-mails $\rightarrow$ Spam

- Existe uma distribuição D **desconhecida** sob pares E-mails x Rótulo de Spam
- Um **conjunto de treino** S com m exemplos **independentes e identicamente distribuídos (iid)**:

$$S = ((x_1, y_1), \dots, (x_m, y_m)) \sim D^m$$

Spam via *Statistical Learning*

Aprendizado Estatístico é um dos mais clássicos arcabouços teóricos de ML.

No Exemplo de Spam:

- Existe uma distribuição D **desconhecida** sob pares E-mails x Rótulo de Spam
- Um **conjunto de treino** S com m exemplos **independentes e identicamente distribuídos (iid)**:

$$S = ((x_1, y_1), \dots, (x_m, y_m)) \sim D^m$$

Queremos achar $h: X \rightarrow Y$ que tenha a maior chance de acertar **em exemplos novos de D** :

$$P[h(x) \neq y] \text{ mais baixo possível} \quad \text{onde } (x, y) \sim D$$

Spam via *Statistical Learning*

Aprendizado Estatístico é um dos mais clássicos arcabouços teóricos de ML.

No Exemplo de Spam:

- Existe uma distribuição D **desconhecida** sob pares E-mails x Rótulo de Spam
- Um **conjunto de treino** S com m exemplos **independentes e identicamente distribuídos (iid)**:

$$S = ((x_1, y_1), \dots, (x_m, y_m)) \sim D^m$$

Queremos achar $h: X \rightarrow Y$ que tenha a maior chance de acertar **em exemplos novos de D** :

$$P[h(x) \neq y] \text{ mais baixo possível} \quad \text{onde } (x, y) \sim D$$

Nota. A chave aqui é a hipótese de que S é gerado I.I.D.

Realista para detecção de spam?

Distribuição igual para novos exemplos?

Spam via Online Learning

A hipótese de dados I.I.D. é muito forte.

Spam via Online Learning

A hipótese de dados I.I.D. é **muito forte**.

Em **Online Learning** temos o extremo oposto: não assumindo nada sobre os dados.

Os dados podem até mesmo serem **adversariais**!

Spam via Online Learning

A hipótese de dados I.I.D. é **muito forte**.

Em **Online Learning** temos o extremo oposto: não assumindo nada sobre os dados.

Os dados podem até mesmo serem **adversariais**!

No Exemplo de Spam:

Os exemplos chegam para o algoritmo de forma **online**. Na rodada t , temos:

- A “**Natureza/Adversário**” mostra um e-mail x_t *sem o rótulo*
- O **algoritmo** prediz se x_t é ou não SPAM
- A “**Natureza/Adversário**” revela o rótulo real y_t

Spam via Online Learning

A hipótese de dados I.I.D. é **muito forte**.

Em **Online Learning** temos o extremo oposto: não assumindo nada sobre os dados.

Os dados podem até mesmo serem **adversariais**!

No Exemplo de Spam:

Os exemplos chegam para o algoritmo de forma **online**. Na rodada t , temos:

- A “**Natureza/Adversário**” mostra um e-mail x_t *sem o rótulo*
- O **algoritmo** prediz se x_t é ou não SPAM
- A “**Natureza/Adversário**” revela o rótulo real y_t

O que seria um **bom algoritmo** nesse caso?

Com dados **adversariais**, o número de erros não é informativo

Spam via Online Learning

A hipótese de dados I.I.D. é **muito forte**.

Em **Online Learning** temos o extremo oposto: não assumindo nada sobre os dados.

Os dados podem até mesmo serem **adversariais**!

No Exemplo de Spam:

Os exemplos chegam para o algoritmo de forma **online**. Na rodada t , temos:

- A “**Natureza/Adversário**” mostra um e-mail x_t *sem o rótulo*
- O **algoritmo** prediz se x_t é ou não SPAM
- A “**Natureza/Adversário**” revela o rótulo real y_t

O que seria um **bom algoritmo** nesse caso?

Com dados **adversariais**, o número de erros não é informativo

Veremos que podemos conseguir poucos erros *comparado* com um **ótimo offline restrito**

Porque Online Learning?

Sem Hipóteses sobre os dados: não assumimos nada sobre a origem dos dados

Menos hipóteses fazem com que tenhamos **garantias em diversos cenários**

Ferramenta para outras áreas: muito usado como ferramenta em TCS, otimização, etc;

Mas tenha em mente: **mais hipóteses** talvez gerassem **resultados mais fortes**

Fundamentos de Statistical Learning ⚡

Notação e Terminologia

$$\{0,1\}^d \mathbb{R}^d$$

$$\begin{matrix} c & l \\ \{ \text{Spem}, \text{Horn} \} \\ \mathbb{R} \end{matrix}$$

Conjunto de atributos $\mathcal{X}$ e rótulos $\mathcal{Y}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y}^{\mathcal{X}} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$

$$\ell(h, (x, y))$$

$$X \rightarrow Y$$

Exemplos

Notação e Terminologia

Conjunto de **atributos** X e **rótulos** Y

Hipótese $h: X \rightarrow Y$ (o que queremos aprender)

Função de custo $\ell: Y^X \times (X \times Y) \rightarrow \mathbb{R}$

Exemplos

Classificação binária: $Y = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$

Usaremos esse cenário durante o resto da aula

Notação e Terminologia

Conjunto de atributos X e rótulos Y

Hipótese $h: X \rightarrow Y$ (o que queremos aprender)

Função de custo $\ell: Y^X \times (X \times Y) \rightarrow \mathbb{R}$

Exemplos

Classificação binária: $Y = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$

Usaremos esse cenário durante o resto da aula

$$h(x) = 0.9$$

Classificação “aleatorizada”: $Y = [0, 1]$ e $\ell(h, (x, y)) = \text{Entropia Cruzada}$

Regressão: $Y = \mathbb{R}$

- $\ell(h, (x, y)) = (h(x) - y)^2$

- $\ell(h, (x, y)) = |h(x) - y|$

Dados IID e Erro de Generalização

Uma das hipóteses mais fortes que fazemos em aprendizado estatístico é que os dados de treino

Assumimos que os **exemplos de treino**

$$S = ((x_1, y_1), \dots, (x_m, y_m))$$

são gerados de forma **independente e identicamente distribuídos** (IID) de uma distribuição $\mathcal{D}$ sob $\mathcal{X} \times \mathcal{Y}$ desconhecida.

Dados IID e Erro de Generalização

Uma das hipóteses mais fortes que fazemos em aprendizado estatístico é que os dados de treino

Assumimos que os **exemplos de treino**

$$S = ((x_1, y_1), \dots, (x_m, y_m))$$

são gerados de forma **independente e identicamente distribuídos** (IID) de uma distribuição D sob $X \times Y$ desconhecida.

Queremos que $h: X \rightarrow Y$ performe bem em *novos dados de D*

O erro de generalização ou risco de $h: X \rightarrow Y$ é dado por

$$L_D(h) := \mathbb{E}[l(h, (x, y))] \text{ onde } (x, y) \sim D$$

$$\mathbb{E}[l(h, (x, y))]$$

Dados IID e Erro de Generalização

Uma das hipóteses mais fortes que fazemos em aprendizado estatístico é que os dados de treino

Assumimos que os **exemplos de treino**

$$S = ((x_1, y_1), \dots, (x_m, y_m))$$

são gerados de forma **independente e identicamente distribuídos** (IID) de uma distribuição D sob $X \times Y$ desconhecida.

Queremos que $h: X \rightarrow Y$ performe bem em *novos dados de D*

O **erro de generalização** ou **risco** de $h: X \rightarrow Y$ é dado por

$$L_D(h) := E[\ell(x, y)] \quad \text{onde } (x, y) \sim D$$

Note que para **classificação binária**, temos que

$$L_D(h) = E[\mathbf{1}[h(x) \neq y]] = P[h(x) \neq y].$$

Handwritten red notes:
 $= 1 \cdot P(h(x) \neq y) + 0 \cdot P(h(x) = y)$

Exemplo - Classificação com retângulos





Figura 2.1 do livro MRT

$$\mathcal{X} = \mathbb{R}^2, \quad \mathcal{Y} = \{0, 1\}$$

$$\mathcal{H} = \{[a, b] \times [c, d]: a, b, c, d \in \mathbb{R}\}$$

Exemplo - Classificação com hiperplanos



$$\mathcal{X} = \mathbb{R}^d, \quad \mathcal{Y} = \{0, 1\}$$

$$\mathcal{H} = \{x \mapsto \text{sign}(\langle w, x \rangle + \beta) : w \in \mathbb{R}^d, \beta \in \mathbb{R}\}$$

Minimizando Risco Empírico (ERM)

O algoritmo mais intuitivo é escolher uma hipótese com **erro mínimo nos dados de treino**

O risco empírico ou erro de treino de $h: \mathcal{X} \rightarrow \mathcal{Y}$ é dado por

$$L_S(h) := \frac{1}{m} \sum_{i=1}^m \ell(h, (x_i, y_i))$$

$$S = ((x_1, y_1), \dots, (x_m, y_m))$$

Minimizando Risco Empírico (ERM)

O algoritmo mais intuitivo é escolher uma hipótese com **erro mínimo nos dados de treino**

O risco empírico ou erro de treino de $h: X \rightarrow Y$ é dado por

$$L_S(h) := \frac{1}{m} \sum_{i=1}^m \ell(h, (x, y))$$

$H = \mathcal{X}$

Problema Existem funções h que são claramente ruins

Exemplo: Predizer $h(x_i) = y_i$ e $h(x) = 0$ caso contrário

O “**No Free Lunch Theorem**” também diz que precisamos de mais hipóteses

Minimizando Risco Empírico (ERM)

O algoritmo mais intuitivo é escolher uma hipótese com **erro mínimo nos dados de treino**

O risco empírico ou erro de treino de $h: X \rightarrow Y$ é dado por

$$L_S(h) := \frac{1}{m} \sum_{i=1}^m \ell(h, (x, y))$$

Problema Existem funções h que são claramente ruins

Exemplo: Predizer $h(x_i) = y_i$ e $h(x) = 0$ caso contrário

O “**No Free Lunch Theorem**” também diz que precisamos de mais hipóteses

Solução: Restringir aprendizado à uma classe de hipóteses $H \subseteq X^Y$:

$$\text{ERM}_H(S) \in \underset{h \in H}{\operatorname{argmin}} L_S(h)$$

O Caso Realizável

Vamos começar analisando o **caso realizável**

$y \sim x$

Diremos que estamos no **caso realizável**, ou que $\mathcal{H}$ realiza $\mathcal{D}$, se existir $h^* \in \mathcal{H}$ tal que

$$\mathbb{P}(h^*(x) = y) = 1 \quad \text{onde } (x, y) \sim \mathcal{D}$$

$\mathcal{D}$ realiza $\mathcal{H}$

$$\mathcal{D} \sim (\mathcal{D}_X, h^*(\cdot))$$

$$h^*(x_i) = y_i$$

$$h(x_i) = y_i \quad h(x_j) = 0$$

O Caso Realizável

Vamos começar analisando o **caso realizável**

Diremos que estamos no **caso realizável**, ou que H realiza D , se existir $h^* \in H$ tal que

$$P(h^*(x) = y) = 1 \quad \text{onde } (x, y) \sim D$$

h^*

$$\log |H|$$

Se, além de realizar D , a classe H for finita, então ERM “**funciona bem**”.

Teorema. No caso realizável, se $S \sim D^m$, então com probabilidade pelo menos $1 - \delta$

$$L_D(\text{ERM}_H(S)) \leq \frac{\log |H| + \log \frac{1}{\delta}}{m}$$

H

$$P(\text{ERM}_H(S)(x) \neq y)$$

$$\mathcal{X} = \{0, 1\}^d, \quad \mathcal{Y} = \{0, 1\}$$

$$2^d \geq 2^d = 2^{2d}$$

$$S \sim \mathcal{D}^m, \quad h_S \in \underset{h \in \mathcal{H}}{\operatorname{argmin}} L_S(h)$$

$$\mathbb{P}(\underline{h_S}(x) \neq y) \leq \varepsilon$$

Soja $h \in \mathcal{H}$

$$\mathbb{P}(L_S(h) = 0) =$$


$$= \mathbb{P}(h(x_1) = y_1 \text{ et } h(x_2) = y_2 \text{ et } \dots \text{ et } h(x_m) = y_m)$$

indep $\uparrow$

$$= \prod_{i=1}^m \underbrace{\mathbb{P}(h(x_i) = y_i)}_{= 1 - L_D(h)} = (1 - L_D(h))^m$$

$$1 - \mathbb{P}(h(x) \neq y) = 1 - L_D(h)$$

$$\Rightarrow \text{Se } h \in \mathcal{H} \text{ á tal que } \mathbb{P}(h(x) = y) > \varepsilon \Rightarrow \mathbb{P}(L_S(h) = 0) =$$



$$\underbrace{P(h(x) \neq y)}_{L_D(h)} > \varepsilon \Rightarrow P(L_S(h) = 0) = (1 - L_D(h))^m$$

$$< (1 - \varepsilon)^m$$


$$\leq e^{-\varepsilon m}$$

$$1 - x \leq e^{-x}$$

$$L_D(h) = P(h(x) \neq y) \\ (x, y \sim D)$$

$$P(\exists h: \underbrace{L_D(h) > \varepsilon}, L_S(h) = 0)$$

$$\mathcal{H}_\varepsilon = \{h: L_D(h) > \varepsilon\} = \{h_1, h_2\}$$



$$\leq \sum_{h \in \mathcal{H}_\varepsilon} \underbrace{P(L_D(h) = 0)}_{e^{-\varepsilon m}} \leq |\mathcal{H}_\varepsilon| \underbrace{e^{-\varepsilon m}}_{= \delta}$$

PAC-Aprendizado

Uma classe de hipóteses $\mathcal{H}$ é **Provavelmente Aproximadamente Correto (PAC)** aprendível se existe um algoritmo $A: (\mathcal{X} \times \mathcal{Y})^* \rightarrow \mathcal{H}$ tal que

- Para todo $\varepsilon, \delta > 0$,
- Para toda distribuição $\mathcal{D}$ sobre $\mathcal{X} \times \mathcal{Y}$ realizada por $\mathcal{H}$,
- Existe $M(\varepsilon, \delta) > 0$ tal que
- Se $m > M(\varepsilon, \delta)$ e $S \sim \mathcal{D}^m$

então

$$\mathbb{P}(L_D(A(S)) \leq \varepsilon) > 1 - \delta$$


Além do Realizável: Aprendizado Agnóstico

No caso **não realizável**, temos que

$$\inf_{h' \in \mathcal{H}} L_D(h') \neq 0 \quad (\text{e potencialmente grande})$$

$\underbrace{P(h'(x) \neq y)}$

Assim, é impossível que para todo $\varepsilon > 0$ consigamos $h \in \mathcal{H}$ com $L_D(h) \leq \varepsilon$.



Além do Realizável: Aprendizado Agnóstico

No caso **não realizável**, temos que

$$\inf_{h' \in H} L_D(h') \neq 0 \quad (\text{e potencialmente grande})$$

Assim, é impossível que para todo $\varepsilon > 0$ consigamos $h \in H$ com $L_D(h) \leq \varepsilon$.

Solução: considerar que conseguimos (PAC-)aprender se achamos h tal que

$$L_D(h) - \inf_{h' \in H} L_D(h') \leq \varepsilon$$

PAC-Aprendizado Agnóstico

Uma classe de hipóteses $\mathcal{H}$ é **Provavelmente Aproximadamente Correto (PAC) aprendível agnosticamente** se existe um algoritmo $A: (\mathcal{X} \times \mathcal{Y})^* \rightarrow \mathcal{H}$ tal que

- Para todo $\varepsilon, \delta > 0$,
- Existe $M(\varepsilon, \delta) > 0$ tal que
- Para toda distribuição $\mathcal{D}$ sobre $\mathcal{X} \times \mathcal{Y}$ ~~realizada por~~ $\mathcal{H}$,
- Se $m > M(\varepsilon, \delta)$ e $S \sim \mathcal{D}^m$

então

$$\mathbb{P}\left(L_{\mathcal{D}}(A(S)) - \inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \leq \varepsilon\right) > 1 - \delta$$

Generalização via Convergência Uniforme

Queremos agora mostrar

$\mathcal{H}$ finito $\implies \mathcal{H}$ PAC Aprendível Agnosticamente por ERM

Generalização via Convergência Uniforme

Queremos agora mostrar

H **finito** $\implies H$ **PAC Aprendível Agnosticamente** por ERM

Para isso, vamos mostrar **convergência uniforme** em H :

$$L_D(h) - L_S(h) \leq \text{BLA} \quad \text{para todo } h \in H$$

$O(m)$

Generalização via Convergência Uniforme

Queremos agora mostrar

H **finito** $\implies H$ **PAC Aprendível Agnosticamente** por ERM

Para isso, vamos mostrar **convergência uniforme** em H :

$$L_D(h) - L_S(h) \leq \text{BLA} \quad \text{para todo } h \in H$$

Isso é o suficiente para mostrar que ERM tem risco perto de $\inf_h L_D(h)$ se $|H| < \infty$:

$$\begin{aligned} & \underline{L_D(\text{ERM}_S)} - \underline{L_D(h^*)} \\ &= L_D(\text{ERM}_S) - L_S(\text{ERM}_S) + L_S(\text{ERM}_S) - L_D(h^*) \end{aligned}$$

Generalização via Convergência Uniforme

Queremos agora mostrar

H **finito** $\implies H$ **PAC Aprendível Agnosticamente** por ERM

Para isso, vamos mostrar **convergência uniforme** em H :

$$L_D(h) - L_S(h) \leq \text{BLA} \quad \text{para todo } h \in H$$

Isso é o suficiente para mostrar que ERM tem risco perto de $\inf_h L_D(h)$ se $|H| < \infty$:

$$\begin{aligned} & L_D(\text{ERM}_S) - L_D(h^*) \\ &= L_D(\text{ERM}_S) - L_S(\text{ERM}_S) + L_S(\text{ERM}_S) - L_D(h^*) \\ &\leq \underbrace{L_D(\text{ERM}_S) - L_S(\text{ERM}_S)} + \underbrace{L_S(h^*) - L_D(h^*)} \end{aligned}$$

Generalização via Convergência Uniforme

Queremos agora mostrar

H **finito** $\implies H$ **PAC Aprendível Agnosticamente** por ERM

Para isso, vamos mostrar **convergência uniforme** em H :

$$L_D(h) - L_S(h) \leq \text{BLA} \quad \text{para todo } h \in H$$

Isso é o suficiente para mostrar que ERM tem risco perto de $\inf_h L_D(h)$ se $|H| < \infty$:

$$\begin{aligned} & L_D(\text{ERM}_S) - L_D(h^*) \\ &= L_D(\text{ERM}_S) - L_S(\text{ERM}_S) + L_S(\text{ERM}_S) - L_D(h^*) \\ &\leq L_D(\text{ERM}_S) - L_S(\text{ERM}_S) + L_S(h^*) - L_D(h^*) \\ &\leq \underbrace{\sup_{h \in H} (L_D(h) - L_S(h))}_{\text{I}} + \underbrace{L_S(h^*) - L_D(h^*)}_{\text{II}} \end{aligned}$$

Concentração: Desigualdade de Hoeffding

A chave da demonstração é mostrar

é pequeno.

$$\mathbb{P}(L_D(h) - L_S(h) > \varepsilon)$$

$$\left(\frac{1}{m} \sum_{i=1}^m \mathbb{1}(h(x_i) \neq y_i) \right)$$

$$\mathbb{P}(|x - \mu| > k) \leq \frac{V k^2}{k^2}$$

$$\mathbb{E}[\mathbb{1}(h(x) \neq y)]$$

Concentração: Desigualdade de Hoeffding

A chave da demonstração é mostrar

$$P(L_D(h) - L_S(h) > \varepsilon)$$

é pequeno.

Observação chave:

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[h(x_i) \neq y_i]$$

é uma soma de variáveis aleatórias Z_i **independentes** com $E[Z_i] = L_D(h)$

Concentração: Desigualdade de Hoeffding

A chave da demonstração é mostrar

$$P(L_D(h) - L_S(h) > \varepsilon)$$

é pequeno.

Observação chave:

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[h(x_i) \neq y_i]$$

é uma soma de variáveis aleatórias Z_i independentes com $E[Z_i] = L_D(h)$

Teorema. (Desigualdade de Hoeffding) Sejam $X_1, \dots, X_m$ variáveis aleatórias independentes com $X_i \in [0, 1]$ com probabilidade 1, e defina $\bar{X} := \frac{1}{m} \sum_{i=1}^m X_i$. Então

$$P(\bar{X} - E[\bar{X}] \geq \varepsilon) \leq \exp(-2m\varepsilon^2) \quad P(\bar{X} - E[\bar{X}] \leq -\varepsilon) \leq \exp(-2m\varepsilon^2)$$

Generalização de Uma Hipótese

Teorema. (Desigualdade de Hoeffding) Sejam $X_1, \dots, X_m$ variáveis aleatórias independentes com $X_i \in [0, 1]$ com probabilidade 1, e defina $\bar{X} := \frac{1}{m} \sum_{i=1}^m X_i$. Então

$$\mathbb{P}(\bar{X} - \mathbb{E}[\bar{X}] \geq \varepsilon) \leq \exp(-2m\varepsilon^2)$$

$$\mathbb{P}(\bar{X} - \mathbb{E}[\bar{X}] \leq -\varepsilon) \leq \exp(-2m\varepsilon^2)$$

Generalização de Uma Hipótese

Teorema. (Desigualdade de Hoeffding) Sejam $X_1, \dots, X_m$ variáveis aleatórias independentes com $X_i \in [0, 1]$ com probabilidade 1, e defina $\bar{X} := \frac{1}{m} \sum_{i=1}^m X_i$. Então

$$P(\bar{X} - E[\bar{X}] \geq \varepsilon) \leq \exp(-2m\varepsilon^2) P(\bar{X} - E[\bar{X}] \leq -\varepsilon) \leq \exp(-2m\varepsilon^2)$$

$$X_i = \mathbb{1}[h(x_i) = y_i]$$

$$\bar{X} = L_S(h)$$

$$E[L_S(h)] = L_D(h)$$

Corolário. Para $h \in H$ fixo, $S \sim D^m$ e $\varepsilon > 0$

$$P(L_S(h) - L_D(h) \geq \varepsilon) \leq \exp(-2m\varepsilon^2) P(L_D(h) - L_S(h) \geq \varepsilon) \leq \exp(-2m\varepsilon^2)$$

ERM Generaliza para $\mathcal{H}$ finito

Teorema. Seja $S \sim \mathcal{D}^m$. Então, com probabilidade pelo menos $1 - \delta$

$$L_D(h) - \underbrace{L_S(h)}_{\substack{\sim \int_{\mathcal{D}} L_D(h) \\ \leftarrow \mu(\mathcal{H})}} \leq \sqrt{\frac{\log |\mathcal{H}| + \log \frac{2}{\delta}}{2m}} \quad \text{para todo } h \in \mathcal{H}$$

Discussão

- Vimos uma definição de aprendizado estatístico: **PAC-Learning**
 - Não é o único modelo existente, mas o mais clássico
 - Uma definição **independente da distribuição**
- Vimos que minimizar a custo nos dados de treino **funciona se** $|\mathcal{H}| < \infty$
 - Isso pode ser generalizado para classes infinitas (prox. aula)
 - ERM não é sempre a melhor coisa a fazer (um pouco disso em aulas futuras);
- Nosso foco foi estudar **condições de $\mathcal{H}$ que o tornam PAC-aprendível**
 - Não vimos: algoritmos, regularização, seleção de modelos, etc...
 - Veremos um pouco de algoritmos em online-to-batch