

Dimensão ~~VC~~ VC, classificação online e dimensão de Littlestone

MAC5005 - Fundamentos Matemáticos do Aprendizado Sequencial e Online

Victor S. Portella
IME-USP

2026-03-02

Relembrando - Aprendizado Estatístico

Conjunto de atributos $\mathcal{X}$ e rótulos $\{0, 1\}$ $\{c_1, \dots, c_{K-1}\}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$ $\ell(h, (x, y)) = \mathbb{1}[h(x) \neq y]$

Distribuição $\mathcal{D}$ desconhecida

Conjunto de treino $S = ((x_1, y_1), \dots, (x_m, y_m))$ gerado IID de $\mathcal{D}$

Relembrando - Aprendizado Estatístico

Conjunto de atributos $\mathcal{X}$ e rótulos $\mathcal{Y}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y}^{\mathcal{X}} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$

Distribuição $\mathcal{D}$ desconhecida

Conjunto de treino $S = ((x_1, y_1), \dots, (x_m, y_m))$ gerado IID de $\mathcal{D}$

- Foco em Classificação binária: $\mathcal{Y} = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$

Relembrando - Aprendizado Estatístico

Conjunto de atributos $\mathcal{X}$ e rótulos $\mathcal{Y}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y}^{\mathcal{X}} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$

Distribuição $\mathcal{D}$ desconhecida

Conjunto de treino $S = ((x_1, y_1), \dots, (x_m, y_m))$ gerado IID de $\mathcal{D}$

- Foco em Classificação binária: $\mathcal{Y} = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$
- Erros de **generalização** e de **treino**:

$$L_{\mathcal{D}}(h) = \underbrace{\mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h, (x, y))]}_{\text{IP}(h(x) \neq y)} \quad \text{e} \quad \boxed{L_S(h)} = \frac{1}{m} \sum_{i=1}^m \ell(h, (x_i, y_i))$$

Relembrando - Aprendizado Estatístico

Conjunto de atributos $\mathcal{X}$ e rótulos $\mathcal{Y}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y}^{\mathcal{X}} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$

Distribuição $\mathcal{D}$ desconhecida

Conjunto de treino $S = ((x_1, y_1), \dots, (x_m, y_m))$ gerado IID de $\mathcal{D}$

- Foco em Classificação binária: $\mathcal{Y} = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$
- Erros de **generalização** e de **treino**:

$$L_{\mathcal{D}}(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h, (x, y))] \quad \text{e} \quad L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, (x_i, y_i))$$

- Classe de hipóteses $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$

Relembrando - Aprendizado Estatístico

Conjunto de atributos $\mathcal{X}$ e rótulos $\mathcal{Y}$

Hipótese $h : \mathcal{X} \rightarrow \mathcal{Y}$ (o que queremos aprender)

Função de custo $\ell : \mathcal{Y}^{\mathcal{X}} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}$

Distribuição $\mathcal{D}$ desconhecida

Conjunto de treino $S = ((x_1, y_1), \dots, (x_m, y_m))$ gerado IID de $\mathcal{D}$

- Foco em Classificação binária: $\mathcal{Y} = \{0, 1\}$ e $\ell(h, (x, y)) = \mathbf{1}[h(x) \neq y]$
- Erros de **generalização** e de **treino**:

$$L_{\mathcal{D}}(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h, (x, y))] \quad \text{e} \quad L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, (x_i, y_i))$$

- Classe de hipóteses $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$
 - **Caso realizável**: Existe $h^* \in \mathcal{H}$ tal que $h^*(x) = y$ com probabilidade 1 ($L_{\mathcal{D}}(h^*) = 0$).

Relembrando - PAC Aprendizado

Uma classe de hipóteses $\mathcal{H}$ é **Provavelmente Aproximadamente Correto** (PAC) **aprendível agnosticamente** se existe um algoritmo $A: (\mathcal{X} \times \mathcal{Y})^* \rightarrow \mathcal{H}$ tal que

- Para todo $\varepsilon, \delta > 0$,
- Existe $M(\varepsilon, \delta) > 0$ tal que
- Para toda distribuição $\mathcal{D}$ sobre $\mathcal{X} \times \mathcal{Y}$ ~~realizada por $\mathcal{H}$~~ ,
- Se $m > M(\varepsilon, \delta)$ e $S \sim \mathcal{D}^m$

então

$$\mathbb{P}(L_{\mathcal{D}}(A(S)) - \inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \leq \varepsilon) > 1 - \delta$$

$\bigcup_{t=1}^t (\mathcal{X} \times \mathcal{Y})^t$

Relembrando - ERM para $\mathcal{H}$ finito

$$\text{ERM}_{\mathcal{H}}(S) \in \underset{h \in \mathcal{H}}{\text{argmin}} L_S(h) = \{h \in \mathcal{H} : L_S(h) \leq L_S(h') \forall h' \in \mathcal{H}\}$$

Teorema. No caso realizável, se $S \sim \mathcal{D}^m$, então com probabilidade pelo menos $1 - \delta$

$$L_{\mathcal{D}}(\text{ERM}_{\mathcal{H}}(S)) \leq \frac{\log |\mathcal{H}| + \log \frac{1}{\delta}}{m}$$

Teorema. Seja $S \sim \mathcal{D}^m$. Então, com probabilidade pelo menos $1 - \delta$

$$L_{\mathcal{D}}(\text{ERM}_{\mathcal{H}}(S)) - \inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \leq \sqrt{\frac{2(\log(|\mathcal{H}| + 1) + \log \frac{1}{\delta})}{m}}$$

$$\sup_h (L_{\mathcal{D}}(h) - L_S(h)) \leq \dots$$

O que acontece quando $\mathcal{H}$
é infinito?


O caso de Thresholds

Na lista 1, vimos que a **classe de thresholds** é PAC-aprendível:

$$\mathcal{H} := \{\mathbf{1}[x \geq \tau] : \tau \in \mathbb{R}\} \quad \text{com } \mathcal{X} = \mathbb{R}.$$

Teorema. Para o caso realizável e $\mathcal{H}$ de thresholds, se $S \sim \mathcal{D}^m$, então

$$L_{\mathcal{D}}(\text{ERM}_{\mathcal{H}}(S)) \leq \frac{\log 2 + \log \frac{1}{\delta}}{m} \quad \text{com prob.} \geq 1 - \delta$$



O caso de Thresholds

Na lista 1, vimos que a **classe de thresholds** é PAC-aprendível:


$$\mathcal{H} := \{\mathbf{1}[x \geq \tau] : \tau \in \mathbb{R}\} \quad \text{com } \mathcal{X} = \mathbb{R}.$$

Teorema. Para o caso realizável e $\mathcal{H}$ de thresholds, se $S \sim \mathcal{D}^m$, então


$$L_{\mathcal{D}}(\text{ERM}_{\mathcal{H}}(S)) \leq \frac{\log 2 + \log \frac{1}{\delta}}{m} \quad \text{com prob. } \geq 1 - \delta$$

No entanto, **nem todo $\mathcal{H}$ é PAC-aprendível.**

Exemplos: $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$ ou $\mathcal{H} = \{x \mapsto \sin(\omega \cdot x) : \omega \in \mathbb{R}\}$




O que Thresholds tem de especial?



No caso realizável:

O que Thresholds tem de especial?



No caso realizável:

- Classificação de alguns pontos de $\mathcal{X}$ já informa a classificação de muitos outros pontos

O que Thresholds tem de especial?



No caso realizável:

- Classificação de alguns pontos de $\mathcal{X}$ já informa a classificação de muitos outros pontos
- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$, isso não é verdade.

O que Thresholds tem de especial?




No caso realizável:

- Classificação de alguns pontos de $\mathcal{X}$ já informa a classificação de muitos outros pontos
- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$, isso não é verdade.
- Como quantificar essa forma de complexidade de $\mathcal{H}$?

Função de crescimento (Growth function)

A função de crescimento de $\mathcal{H}$ é dada por

$$\Pi_{\mathcal{H}}(m) = \max_{\underbrace{x_1, \dots, x_m \in \mathcal{X}}_{\text{red bracket}}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$



Função de crescimento (Growth function)

A função de crescimento de $\mathcal{H}$ é dada por

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$

- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$ e $\mathcal{X}$ infinito, $\Pi_{\mathcal{H}}(m) = 2^m$ para todo m .

Função de crescimento (Growth function)

A função de crescimento de $\mathcal{H}$ é dada por

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$

- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$ e $\mathcal{X}$ infinito, $\Pi_{\mathcal{H}}(m) = 2^m$ para todo m .
- Para $\mathcal{H}$ de thresholds, $\Pi_{\mathcal{H}}(m) = m + 1$ para todo m

Função de crescimento (Growth function)

A função de crescimento de $\mathcal{H}$ é dada por

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$

- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$ e $\mathcal{X}$ infinito, $\Pi_{\mathcal{H}}(m) = 2^m$ para todo m .
- Para $\mathcal{H}$ de thresholds, $\Pi_{\mathcal{H}}(m) = m + 1$ para todo m

Intuição: Mesmo que $|\mathcal{H}| = \infty$, o que importa é o comportamento no conj. de treino S

Cota da união em $\mathcal{H}$ restrito a S ao invés de $\mathcal{H}$ inteiro.

Função de crescimento (Growth function)

A função de crescimento de $\mathcal{H}$ é dada por

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|$$

- Para $\mathcal{H} = \mathcal{Y}^{\mathcal{X}}$ e $\mathcal{X}$ infinito, $\Pi_{\mathcal{H}}(m) = 2^m$ para todo m .
- Para $\mathcal{H}$ de thresholds, $\Pi_{\mathcal{H}}(m) = m + 1$ para todo m

Intuição: Mesmo que $|\mathcal{H}| = \infty$, o que importa é o comportamento no conj. de treino S

Cota da união em $\mathcal{H}$ restrito a S ao invés de $\mathcal{H}$ inteiro.

Teorema. (Eq. 3.23 de [MRT]) Com probabilidade pelo menos $1 - \delta$,

$$L_{\mathcal{D}}(h) - L_S(h) \leq \sqrt{\frac{8(\log(4 \cdot \Pi_{\mathcal{H}}(2m)) + \log(1/\delta))}{m}}$$

$\tilde{n}$ realy val
 $\mathcal{H}$ inf.
 $\forall h \in \mathcal{H}.$

Dimensão VC (Vapnik-Chervonenkis)

O que importa não é o **valor** de $\Pi_{\mathcal{H}}(m)$, mas sim seu **crescimento**

Dimensão VC (Vapnik-Chervonenkis)

O que importa não é o **valor** de $\Pi_{\mathcal{H}}(m)$, mas sim seu **crescimento**

$\Pi_{\mathcal{H}}(m) \leq m^d$ para algum d e todo m é suficiente para PAC-aprendizado

$$L_D(h) - L_S(h) \leq \frac{\sqrt{\log \Pi_{\mathcal{H}}(m)}}{\sqrt{m}}$$

Dimensão VC (Vapnik-Chervonenkis)

O que importa não é o **valor** de $\Pi_{\mathcal{H}}(m)$, mas sim seu **crescimento**

$\Pi_{\mathcal{H}}(m) \leq m^d$ para algum d e todo m é suficiente para PAC-aprendizado

$\Pi_{\mathcal{H}}(m)$ pode ser difícil de calcular

Dimensão VC (Vapnik-Chervonenkis)


O que importa não é o **valor** de $\Pi_{\mathcal{H}}(m)$, mas sim seu **crescimento**

$\Pi_{\mathcal{H}}(m) \leq m^d$ para algum d e todo m é suficiente para PAC-aprendizado

$\Pi_{\mathcal{H}}(m)$ pode ser difícil de calcular

A dimensão VC de $\mathcal{H}$ é dado por

$$VC(\mathcal{H}) := \sup\{m \in \mathbb{N} : \Pi_{\mathcal{H}}(m) = 2^m\}$$



Dimensão VC (Vapnik-Chervonenkis)

O que importa não é o **valor** de $\Pi_{\mathcal{H}}(m)$, mas sim seu **crescimento**

$\Pi_{\mathcal{H}}(m) \leq m^d$ para algum d e todo m é suficiente para PAC-aprendizado

$\Pi_{\mathcal{H}}(m)$ pode ser difícil de calcular

A dimensão VC de $\mathcal{H}$ é dado por


$$\underbrace{\text{VC}(\mathcal{H})}_d := \sup\{m \in \mathbb{N} : \Pi_{\mathcal{H}}(m) = 2^m\}$$

Note que $\text{VC}(\mathcal{H}) = d$ se e somente se:

- Existe $S = (x_1, \dots, x_d) \in \mathcal{X}^d$ tal que $\mathcal{H}$ fragmenta S , isto é


$$\{(h(x_1), \dots, h(x_d)) : h \in \mathcal{H}\} = \{0, 1\}^d$$

- Para todo $\hat{S} \in \mathcal{X}^{d+1}$, temos que $\mathcal{H}$ não fragmenta $\hat{S}$



Exemplo - Thresholds

$$VC(H) \geq 1$$



Exemplo - Hiperplanos

$$VC(H) = 3$$






Fig. 3.2 de [MRT]



Conectando Dimensão VC e $\Pi_{\mathcal{H}}(m)$

Pergunta: Podemos controlar a **função de crescimento** em termos da **dimensão VC**?

- Se $m \leq \text{VC}(\mathcal{H})$, então $\Pi_{\mathcal{H}}(m) = 2^m$, não é interessante.
- E se $m > \text{VC}(\mathcal{H})$?

Conectando Dimensão VC e $\Pi_{\mathcal{H}}(m)$

Pergunta: Podemos controlar a **função de crescimento** em termos da **dimensão VC**?

- Se $m \leq \text{VC}(\mathcal{H})$, então $\Pi_{\mathcal{H}}(m) = 2^m$, não é interessante.
- E se $m > \text{VC}(\mathcal{H})$?

Lema. (Lema de Sauer) Se $\mathcal{H} \subseteq \mathcal{X}^{\{0,1\}}$, então para todo $m \geq 0$

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^{\text{VC}(\mathcal{H})} \binom{m}{i}.$$

$$\frac{m!}{i!(m-i)!}$$

Em particular, se $m \geq \text{VC}(\mathcal{H})$

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{\text{VC}(\mathcal{H})} \right)^{\text{VC}(\mathcal{H})}.$$

Generalização em termos da Dimensão VC

O Lema de Sauer junto da generalização usando $\Pi_{\mathcal{H}}(m)$ nos levam à seguinte garantia:

Corolário. Com probabilidade pelo menos $1 - \delta$, $m \geq VC(\mathcal{H})$

$$L_{\mathcal{D}}(h) - L_S(h) \leq \sqrt{\frac{8}{m}} \cdot \sqrt{\frac{VC(\mathcal{H}) \log(4em) + \log(1/\delta)}{m}} \quad \forall h \in \mathcal{H}.$$

Em particular, $\mathcal{H}$ é PAC-aprendível se $VC(\mathcal{H}) < \infty$.

Generalização em termos da Dimensão VC

O Lema de Sauer junto da generalização usando $\Pi_{\mathcal{H}}(m)$ nos levam à seguinte garantia:

Corolário. Com probabilidade pelo menos $1 - \delta$,

$$L_{\mathcal{D}}(h) - L_S(h) \leq \sqrt{\frac{8}{m}} \cdot \sqrt{\frac{\text{VC}(\mathcal{H}) \log(4em) + \log(1/\delta)}{m}} \quad \forall h \in \mathcal{H}.$$

Em particular, $\mathcal{H}$ é PAC-aprendível se $\text{VC}(\mathcal{H}) < \infty$.

Além disso, temos a seguinte impossibilidade.

Teorema. Se $\text{VC}(\mathcal{H}) = \infty$, então $\mathcal{H}$ não é PAC-aprendível.

Extra - Além de ERM e Dimensão VC

Diversos tópicos fundamentais em generalização que estamos pulando:

- Complexidade de Radamacher (depende da **distribuição**)
- Estabilidade algorítmica (depende do **algoritmo**)
- Generalização **além de classificação binária** (regressão, classificação multiclasse, etc)

Extra - Além de ERM e Dimensão VC

Diversos tópicos fundamentais em generalização que estamos pulando:

- Complexidade de Radamacher (depende da **distribuição**)
- Estabilidade algorítmica (depende do **algoritmo**)
- Generalização **além de classificação binária** (regressão, classificação multiclasse, etc)

Ainda é um tópico com pesquisa interessante




FIGURE 1: Illustration of the difference between universal and uniform rates. Each red curve shows exponential decay of the error for a different data distribution P ; but the PAC rate only captures the pointwise supremum of these curves (blue curve) which decays linearly at best.

Classificação Binária

Online

Classificação Binária Online

Para cada rodada $t = 1, \dots, T$:

- O **Adversário** escolhe um $x_t \in \mathcal{X}$
- O **Jogador/Algoritmo** escolhe uma predição $p_t \in \mathcal{Y} = \{0, 1\}$
- O **Adversário** escolhe e revela o rótulo real $y_t \in \{0, 1\}$

Classificação Binária Online

Para cada rodada $t = 1, \dots, T$:

- O **Adversário** escolhe um $x_t \in \mathcal{X}$
- O **Jogador/Algoritmo** escolhe uma predição $p_t \in \mathcal{Y} = \{0, 1\}$
- O **Adversário** escolhe e revela o rótulo real $y_t \in \{0, 1\}$

Assim como no aprendizado estatístico, vamos começar pelo **caso realizável**:

Temos uma classe de hipóteses $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ conhecida, e existe $h^* \in \mathcal{H}$ tal que

$$y_t = h^*(x_t) \quad \text{para todo } t \in [T] := \{1, \dots, T\}.$$

Classificação Binária Online

Para cada rodada $t = 1, \dots, T$:

- O **Adversário** escolhe um $x_t \in \mathcal{X}$
- O **Jogador/Algoritmo** escolhe uma predição $p_t \in \mathcal{Y} = \{0, 1\}$
- O **Adversário** escolhe e revela o rótulo real $y_t \in \{0, 1\}$

Assim como no aprendizado estatístico, vamos começar pelo **caso realizável**:

Temos uma classe de hipóteses $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ conhecida, e existe $h^* \in \mathcal{H}$ tal que

$$y_t = h^*(x_t) \quad \text{para todo } t \in [T] := \{1, \dots, T\}.$$

Importante: não assumimos mais nada sobre o adversário

Classificação Binária Online

Para cada rodada $t = 1, \dots, T$:

- O **Adversário** escolhe um $x_t \in \mathcal{X}$
- O **Jogador/Algoritmo** escolhe uma predição $p_t \in \mathcal{Y} = \{0, 1\}$
- O **Adversário** escolhe e revela o rótulo real $y_t \in \{0, 1\}$

Assim como no aprendizado estatístico, vamos começar pelo **caso realizável**:

Temos uma classe de hipóteses $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ conhecida, e existe $h^* \in \mathcal{H}$ tal que

$$y_t = h^*(x_t) \quad \text{para todo } t \in [T] := \{1, \dots, T\}.$$

Importante: não assumimos mais nada sobre o adversário

Pergunta Qual o número máximo de erros que o algoritmo pode fazer?

Um primeiro algoritmo: CONSISTENTE

Vamos primeiro considerar o caso **finito**: $|\mathcal{H}| < \infty$.

Um primeiro algoritmo: CONSISTENTE

Vamos primeiro considerar o caso **finito**: $|\mathcal{H}| < \infty$.

Ideia: A cada rodada t , o jogador escolhe uma hipótese que concorda com as rodadas anteriores:

$$\mathcal{V}_t := \{h \in \mathcal{H} : h(x_s) = y_s \text{ para todo } s < t\}$$

Um primeiro algoritmo: CONSISTENTE


Vamos primeiro considerar o caso **finito**: $|\mathcal{H}| < \infty$.

Ideia: A cada rodada t , o jogador escolhe uma hipótese que concorda com as rodadas anteriores:

$$\mathcal{V}_t := \{h \in \mathcal{H} : h(x_s) = y_s \text{ para todo } s < t\}$$

Na rodada $t \in [T]$, O algoritmo **CONSISTENTE**

- Escolhe $h_t \in \mathcal{V}_t$
- Define $p_t = h_t(x_t)$



Um primeiro algoritmo: **CONSISTENTE**

Vamos primeiro considerar o caso **finito**: $|\mathcal{H}| < \infty$.

Ideia: A cada rodada t , o jogador escolhe uma hipótese que concorda com as rodadas anteriores:

$$\mathcal{V}_t := \{h \in \mathcal{H} : h(x_s) = y_s \text{ para todo } s < t\}$$

Na rodada $t \in [T]$, O algoritmo **CONSISTENTE**

- Escolhe $h_t \in \mathcal{V}_t$
- Define $p_t = h_t(x_t)$



Teorema. Para p_t dado por **CONSISTENTE**,

$$\sum_{t=1}^T \mathbf{1}[p_t \neq y_t] \leq |\mathcal{H}| - 1$$

O algoritmo HALVING

Podemos fazer algo **muito melhor** que CONSISTENTE.

Ideia: Predizer de acordo com a **maioria** a cada rodada.

O algoritmo **HALVING**

Podemos fazer algo **muito melhor** que **CONSISTENTE**.

Ideia: Predizer de acordo com a **maioria** a cada rodada.

Na rodada $t \in [T]$, O algoritmo **HALVING**

- Escolhe $p_t \in \{0, 1\}$ que maximiza o tamanho do conjunto

$$\{h \in \mathcal{V}_t : h(x_t) = p_t\}$$



~~X_t~~

$$|\mathcal{V}_{t+1}| \leq \frac{|\mathcal{V}_t|}{2}$$

O algoritmo HALVING

Podemos fazer algo **muito melhor** que CONSISTENTE.

Ideia: Predizer de acordo com a **maioria** a cada rodada.

Na rodada $t \in [T]$, O algoritmo **HALVING**

- Escolhe $p_t \in \{0, 1\}$ que maximiza o tamanho do conjunto

$$\{h \in \mathcal{V}_t: h(x_t) = p_t\}$$

Teorema. Para p_t dado por **HALVING**,

$$\sum_{t=1}^T \mathbf{1}[p_t \neq y_t] \leq \log_2(|\mathcal{H}|)$$

E para $\mathcal{H}$ infinito?

Nenhum dos dois algoritmos tem garantias no número de erros quando $|\mathcal{H}| = \infty$

HALVING não está nem bem definido

E para $\mathcal{H}$ infinito?

Nenhum dos dois algoritmos tem garantias no número de erros quando $|\mathcal{H}| = \infty$

HALVING não está nem bem definido

Vamos começar interpretando as estratégias do adversário como **uma árvore binária de profundidade T** .

E para $\mathcal{H}$ infinito?

Nenhum dos dois algoritmos tem garantias no número de erros quando $|\mathcal{H}| = \infty$

HALVING não está nem bem definido

Vamos começar interpretando as estratégias do adversário como **uma árvore binária de profundidade T** .

Uma **árvore de estratégia** (do adversário) é uma árvore binária completa de altura T com conjunto de vértices é $v_1, \dots, v_{2^{T+1}-1} \in \mathcal{X}$ com v_1 de raiz.

Arestas e Notação:

- $\text{DESC}(v_i, 0) := v_{2i}$ (filho esquerdo de v)
- $\text{DESC}(v, 1) := v_{2i+1}$ (filho direito de v)



E para $\mathcal{H}$ infinito?

Nenhum dos dois algoritmos tem garantias no número de erros quando $|\mathcal{H}| = \infty$

HALVING não está nem bem definido

Vamos começar interpretando as estratégias do adversário como uma **árvore binária de profundidade T** .

Uma **árvore de estratégia** (do adversário) é uma árvore binária completa de altura T com conjunto de vértices $v_1, \dots, v_{2^T-1} \in \mathcal{X}$ com v_1 de raiz.


Arestas e Notação:

- $\text{DESC}(v_i, 0) := v_{2i}$ (filho esquerdo de v)
- $\text{DESC}(v, 1) := v_{2i+1}$ (filho direito de v)

As escolhas do **adversário** são dadas pela árvore.

- **Adversário** escolhe $x_t = v_{2^{t-1}}$ (v_1 se $t = 1$);
- **Adversário** espera p_t , e define $y_t = |1 - p_t|$;

$$v_{k+1} \leftarrow \text{Desc}(v_k, y_k)$$



Árvore fragmentada por $\mathcal{H}$

Jogador erra em toda rodada.

Adversário ainda é realizado por $\mathcal{H}$?

Árvore fragmentada por $\mathcal{H}$

Jogador erra em toda rodada.

Adversário ainda é realizado por $\mathcal{H}$?

Depende de $\mathcal{H}$ e da árvore!

Árvore fragmentada por $\mathcal{H}$

Jogador erra em toda rodada.

Adversário ainda é realizado por $\mathcal{H}$?

Depende de $\mathcal{H}$ e da árvore!

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é fragmentada por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T-1],$$

existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.



Árvore fragmentada por $\mathcal{H}$

Jogador erra em toda rodada.


Adversário ainda é realizado por $\mathcal{H}$?

Depende de $\mathcal{H}$ e da árvore!

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é **fragmentada** por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T-1],$$

existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.



	h_1	h_2	h_3	h_4
v_1	0	0	1	1
v_2	0	1	*	*
v_3	*	*	0	1

Dimensão de Littlestone

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é fragmentada por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T-1],$$

existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.

Dimensão de Littlestone

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é fragmentada por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T-1],$$

existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.

Assim como em aprendizado estatístico, a ideia de **fragmentação** nos leva a uma noção de **dimensão de $\mathcal{H}$**

Dimensão de Littlestone

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é fragmentada por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T - 1],$$

existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.

Assim como em aprendizado estatístico, a ideia de **fragmentação** nos leva a uma noção de **dimensão de $\mathcal{H}$**

A **dimensão de Littlestone** $\text{LDim}(\mathcal{H})$ de $\mathcal{H}$ é o maior $T \in \mathbb{N}$ tal que existe uma árvore de estratégia de profundidade T fragmentada por $\mathcal{H}$

Dimensão de Littlestone

Uma árvore de estratégia com vértices $(v_1, \dots, v_{2^{T+1}-1})$ é fragmentada por $\mathcal{H}$ se **para todo** $y \in \{0, 1\}^T$, definindo $x_1 = v_1$ e

$$x_{t+1} = \text{DESC}(x_t, y_t) \quad \text{para todo } t \in [T - 1],$$


existe $h \in \mathcal{H}$ tal que $h(x_t) = y_t$ para todo $t \in [T]$.

Assim como em aprendizado estatístico, a ideia de **fragmentação** nos leva a uma noção de **dimensão de $\mathcal{H}$**

A **dimensão de Littlestone** $\text{LDim}(\mathcal{H})$ de $\mathcal{H}$ é o maior $T \in \mathbb{N}$ tal que existe uma árvore de estratégia de profundidade T fragmentada por $\mathcal{H}$

Lema. Nenhum algoritmo pro jogador contra um adversário realizado por $\mathcal{H}$ pode garantir menos que $\text{LDim}(\mathcal{H})$ erros.

Exemplo - $\mathcal{H}$ finito




$|\mathcal{H}|$ folhas

$$\mathcal{H} = \{h_1, h_2, h_3, h_4\}$$

$$Alt_m \leq \log |\mathcal{H}|$$

Exemplo - Thresholds



Ex. 21.4 de [SSBD]

